RAG 검색 실습: 무엇을 만들고 어떻게 진행하나

인덱싱 실습이 만든 색인을 읽어 교재 150쪽 워크플로우 6단계를 돌리고, LLM은 제안만 하고 결정은 코드 규칙이 맡음

만드는 것(교재 150쪽 워크플로우)

① 권한 필터: 역할과 회원으로 볼 수 있는 청크만 남김(벡터는 Chroma 필터, BM25는 마스크)

② Adaptive 분류: LLM이 유형을 제안하고 코드 규칙이 잡담, 단순, 복합으로 확정함

③ 검색: 벡터 + BM25를 6 : 4로 융합한 뒤 Cohere 리랭크로 근거 5개를 고름

④ CRAG 채점: 신호로 정확, 불확실, 부정확을 판정, 불확실이면 질문 변환 후 재검색

⑤ 답변 생성: 근거만으로 문장마다 청크ID와 인용문을 달아 씀(Groq)

⑥ Self-RAG 검증: 인용문을 근거 본문과 글자 대조, 실패면 ⑤ 재작성 최대 2회

수업 흐름(4교시)

교시	내용	실습 함수
1 이론	교재 144 ~ 174쪽	-
2	① ② ③ 벡터	3개(빈칸 3)
3	③ BM25, 융합, 리랭크	3개(직접 2, 빈칸 1)
4	④ ⑤ ⑥	4개(직접 2, 빈칸 2)

실습 방식

- 10개 함수(직접 4, 빈칸 6)를 my_search.py에 채움
- 안 채운 함수는 강사 코드가 대신 돌아 늘 끝까지 완주
- 한 함수를 고칠 때마다 질문 한두 개만 실행

LLM은 제안만 하고, 받아들일지는 코드 규칙이 정함. 채점과 검증은 LLM 없이 규칙으로만 함(교재 152쪽)

상세 보기 →

출처: 『신한카드 하이브리드AI_W01 ~ W04』 144 ~ 174쪽, teacher/plan/rag-search-개발계획서.md 4장

무단전재 및 배포 금지

사전 준비 4가지와 수업에서 쓰는 명령 2개

시작 검사가 색인 폴더와 키를 확인하고 모자란 것을 알려 주며, 로컬 모델 없이 임베딩, 리랭크, LLM 모두 API로 호출함

사전 준비(수업 전)

1. 인덱싱 실습 완료(chroma, bm25 폴더). 없으면 강사 배포본 복사
2. 저장소를 통째로 clone(secrets, eval-set.json 상대 경로)
3. rag 폴더에서 가상환경 활성화: .venv\Scripts\Activate.ps1(README 3장)
4. secrets/.env에 키 2줄: GROQ, COHERE

수업용 명령 2개(활성화 뒤 retriever 폴더에서)

python search_docs.py --qid Q01

약관 질문을 ① ~ ⑥ 끝까지(약 4초). 「답변 완료」를 봄

python search_docs.py --qid Q18

답 없는 질문이 지어내지 않고 되묻기 또는 「확인 필요」로 끝남. 프롬프트에 (.venv)가 없으면 먼저 활성화

출력 줄	봐야 할 것	Q01(강사 PC)
① 권한 필터	역할, BM25 대상 청크 수	agent, 212개(전체 260개 중)
③ 리랭크	융합 n위 → 리랭크 m위, 점수	D1-0007이 1위, 0.908
④ CRAG 채점	신호와 기준값, 판정	판정 정확
⑥ 검증, 종료	검증 결과, 종료 상태	검증 통과, 답변 완료

PowerShell에서 활성화가 막히면 먼저 Set-ExecutionPolicy -Scope Process -ExecutionPolicy Bypass

상세 보기 →

출처: hands-on/solutions/rag/retriever/README.md 3 ~ 5장, 2026-10-26 강사 PC 실측

무단전재 및 배포 금지

교시 2: ① 권한 필터, ② 분류, ③ 벡터(실습 함수 3개)

세 함수 모두 빈칸 채우기이고, 권한 필터와 분류 규칙, 벡터 검색 호출의 「무엇을 어떤 순서로 쓰나」가 개념임

단계	함수	방식	채울 것(실습 개념)	줄 수
①	build_chroma_filter	빈칸 2	agent는 public만($eq), auditor + 회원은 그 회원의 restricted만($and)	15
②	apply_plan_rules	빈칸 3	업무 낱말 있는 잡담은 단순, 하위 질문 앞 3개, 조건 낱말 집합 빼기	35
③ 벡터	search_vector	빈칸 2	similarity_search_with_score(질의, k, filter), 거리를 점수로 바꿈	20

교시 끝에 확인할 출력

- ① Q14: BM25 대상 4개, agent는 212개
- ② 「안녕하세요」: 잡담, 검색 0회
- ③ Q01: 정답 청크 점수 0.45 ~ 0.6

보는 포인트

- 권한은 LLM이 아니라 코드가 검색 전에 정함
- LLM은 제안만, 받아들일지는 규칙이 정함
- 점수는 절댓값보다 순위를 봄

권한 필터는 검색 전에 코드가 만들고, 벡터는 Chroma 필터, BM25는 0과 1 마스크로 거름(교재 151쪽)

상세 보기 →

출처: hands-on/solutions/rag/retriever/core_search.py, README.md 5, 6장, 교재 151 ~ 160쪽

무단전재 및 배포 금지

교시 3: ③ BM25, 융합, 리랭크(실습 함수 3개)

BM25 정렬과 가중합 융합은 순수 파이썬 논리라 직접 작성이고, 리랭크 API 호출만 빈칸 채우기임

단계	함수	방식	채울 것(실습 개념)	줄 수
③ BM25	search_bm25	직접	청크별 점수, 0점은 버림, 내림차순 정렬, 앞 top_n개를 dict로	20
③ 융합	fuse_weighted	직접	0 ~ 1로 정규화 뒤 벡터 0.6 + BM25 0.4, 없는 쪽은 0점	20
③ 리랭크	rerank	빈칸 2	cohere_client.rerank(model, query, documents, top_n), index로 후보 찾기	25

교시 끝에 확인할 출력

- BM25: 카드명이 한 토큰(한빛모아생활)
- 융합: 양쪽 1위면 1.0
- 리랭크: 정답 0.7 이상, 무관 0.3 이하

보는 포인트

- BM25 점수는 상한이 없음(0 ~ 수십)
- 두 점수를 0 ~ 1로 맞춘 뒤 합침
- 리랭크는 질문과 청크를 한 쌍으로 채점

> ***BM25 점수는 0 ~ 수십이라 그대로 더하면 BM25가 결과를 좌우함. 그래서 정규화 뒤 6 : 4로 합침(교재 161쪽)***

상세 보기 →

출처: hands-on/solutions/rag/retriever/core_search.py, README.md 5, 6장, 교재 157 ~ 166쪽

무단전재 및 배포 금지

교시 4: ④ 채점과 질문 변환, ⑤ 답변, ⑥ 검증(함수 4개)

채점과 근거 검증은 직접 작성, 질문 변환 금지 규칙과 LCEL 체인은 빈칸 채우기임

단계	함수	방식	채울 것(실습 개념)	줄 수
④ 채점	grade	직접	부정확(하나라도), 정확(모두), 나머지는 불확실	20
④ 질문 변환	apply_transform_rules	빈칸 3	대상 섞임이면 clarify, 같은 질의 제외, HyDE와 Step-Back은 원 질의 포함	35
⑤	generate_answer	빈칸 2	with_structured_output(GroundedAnswer), LCEL 체인으로 프롬프트와 모델 잇기	20
⑥	verify_answer	직접	청크ID 있음, 근거에 있음, 인용문이 본문에 글자 그대로 있음	25

교시 끝에 확인할 출력

- Q01: 검증 통과
- Q18: 「확인 필요:」만 나오고 ⑥ 건너뜀
- 불확실이면 질문 변환, 재검색 1/1

보는 포인트

- 같은 결과면 언제나 같은 판정
- 금지 규칙은 LLM 답과 상관없이 적용
- 「확인 필요」도 정상 종료

⑥ 검증은 인용문이 본문에 글자 그대로 있는지만 봄. 인용은 맞는데 해석이 틀린 답은 못 거름(README 9장)

상세 보기 →

출처: hands-on/solutions/rag/retriever/core_search.py, README.md 5, 6, 9장, 교재 149, 167 ~ 174쪽

무단전재 및 배포 금지

본인 코드로 바꿔 끼우기: import 한 줄과 USE_TEACHER_CODE 목록

안 채운 함수는 강사 코드가 대신 돌므로 한 함수씩 채우며 전체를 끝까지 돌려 볼 수 있음

교체 절차

1. search_docs.py의 import 한 줄을 import my_search as core 로 바꿈
2. my_search.py 맨 아래 USE_TEACHER_CODE 목록에서 채울 함수 이름을 지움
3. 그 함수를 채우고(raise 줄은 지움) 확인 명령으로 실행함
4. 정상 기준(대상 청크 수, 판정, 종료 상태)을 강사 결과와 비교함
5. 막히면 이름을 목록에 다시 넣고 다음 함수로 넘어감

완료 기준

- USE_TEACHER_CODE가 빈 my_search.py로 Q01이 「답변 완료」, ⑥ 검증 통과
- Q18이 되묻기 또는 「확인 필요」로 끝남
- Q14의 BM25 대상 4개, --role agent는 212개
- 제출: my_search.py와 Q01, Q18 실행 화면 캡처

막혔을 때

- NotImplementedError 빈칸 N: 아직 안 채움 또는 raise 줄을 안 지움
- 429(호출 제한): 1 ~ 2분 뒤 다시, 수정 반복은 --no-answer
- 강사와 답 문장이 다름: 정상(판정으로 비교)

> ***본인 함수에서 예외가 나면 감추지 않고 Traceback을 그대로 보여 주고 그 질문만 「오류」로 끝남***

상세 보기 →

출처: hands-on/solutions/rag/retriever/my_search.py, README.md 6장과 8장

무단전재 및 배포 금지