RAGAS 평가 실습: 무엇을 만들고 어떻게 진행하나

설정 하나만 바꾼 버전들을 같은 평가셋과 지표로 채점해 기준선과 비교하고 원인을 찾음

만드는 것(교재 177쪽 버전 비교 평가)

① 버전 만들기: 값 목록(top_k 3, 5, 10)을 버전 v01, v02, v03으로 만들고 기준선에 ★

② 검색기 실행: 버전마다 문항마다 강사 검색기를 돌려 결과 정보 4칸을 만듦

③ 코드 평가: 정답 단서를 글자로 대조해 Hit, Recall, MRR, nDCG 계산(LLM 없음)

④ LLM 평가: 평가자 LLM이 위, 정, 출, 관, 답 5지표를 채점(ragas 0.4.3)

⑤ 버전 비교: 버전별 평균과 기준선 대비 ▲, ▼, 변화 없음, 원인 후보

한 번에 하나만 바꿔 같은 평가셋과 지표로 기준선과 비교함(교재 177쪽)

수업 흐름(3교시)

교시	내용	실습 함수
1 이론	교재 176 ~ 193쪽, 결과 읽기	-
2	① ② ③ 버전, 결과 정보, 코드 평가	5개(직접 3, 빈칸 2)
3	⑤ 비교, ④ LLM 평가	4개(직접 1, 빈칸 3)

실습 방식

- 9개 함수(직접 4, 빈칸 5)를 my_eval.py에 채움
- 안 채운 함수는 강사 코드가 대신 돌아 늘 끝까지 완주
- 검색기는 언제나 강사 코드(--mine은 평가 함수만 바꿈)

상세 보기 →

출처: 『신한카드 하이브리드AI_W01 ~ W04』 176 ~ 193쪽, teacher/plan/ragas-개발계획서.md 1장, 4장

무단전재 및 배포 금지

사전 준비 4가지와 수업에서 쓰는 명령 2개

이 폴더 전용 가상환경을 쓰고, 시작 검사가 색인, 키, 정답 단서를 확인해 빠진 것을 알려 줌

사전 준비(수업 전)

1. 인덱싱 실습 완료(chroma, bm25 폴더). 없으면 강사 배포본 복사
2. 저장소를 통째로 clone(secrets, eval-set.json 상대 경로)
3. ragas 폴더의 .venv 활성화(rag/.venv가 아님, README 3장)
4. secrets/.env에 키 2줄: GROQ, COHERE(평가자도 Groq)

수업용 명령 2개(활성화 뒤 ragas 폴더에서)

python evaluate_rag.py --selftest

API 없이 교재 181쪽 예로 계산 함수를 점검함. 끝에 「맞음 12/12」를 봄

python evaluate_rag.py --param top_k --values 3 5 10 --until code --qid Q01 Q17 Q20

버전 3개를 문항 3개로 돌려 코드 4지표와 비교표를 봄(LLM 평가는 건너뜀)

출력 줄	봐야 할 것	정상 기준
① 버전	v01, v02 ★, v03	기준선은 v02(5)
③ Q17	정답 근거 3/3	Hit 1, Recall 1.00, MRR 1.00, nDCG 0.97
Q20	「확인 필요」 판정	맞음(지표는 계산 안 함)

PowerShell에서 활성화가 막히면 먼저 Set-ExecutionPolicy -Scope Process -ExecutionPolicy Bypass

상세 보기 →

출처: hands-on/solutions/ragas/README.md 3 ~ 5장, 2026-10-31 --selftest 실행과 README 5.1장 Q17 값

무단전재 및 배포 금지

교시 1: 결과 읽기, 점수보다 기준선 대비 변화를 봄

고정 합격선 대신 기준선보다 얼마나 달라졌나를 보고, 떨어진 지표 조합으로 고칠 곳을 고름

변화 표시	뜻	정해지는 방식
▲	기준선보다 나아짐	평균 차이가 흔들림 폭보다 큼
▼	기준선보다 나빠짐	평균 차이가 흔들림 폭의 음수보다 작음
변화 없음	차이가 흔들림 폭 안	초깃값 0.03(--repeat 3이면 LLM 지표는 실측)
-	기준선 자신	자기 자신과는 비교하지 않음
비교 불가	평균을 낼 점수가 없음	모두 None(계산 안 함) 또는 nan(채점 실패)

결과 파일 읽는 순서

- 요약에서 기준선 대비 ▲, ▼ 찾기
- 원인 후보 문장 읽기(교재 187쪽 표)
- 0점 문항은 문항별 표와 상세로 내려감

조심할 점

- 평균 차이 0.125 미만은 의미를 두지 않음
- top_k가 크면 Hit, Recall이 기계적으로 오름
- 통계적 유의성은 주장하지 않음

> ***0.8점 같은 고정 합격선보다 기준선 대비 변화로 채택 여부를 정함(교재 187쪽)***

상세 보기 →

출처: hands-on/solutions/ragas/README.md 5장, core_eval.py summarize_versions, 교재 177, 187쪽

무단전재 및 배포 금지

교시 2: ① 버전, ② 결과 정보, ③ 코드 평가(실습 함수 5개)

버전 만들기와 적중 판정, 지표 계산은 직접 쓰고, 결과 정보 칸 채우기와 nDCG는 빈칸을 채움

단계	함수	방식	채울 것(실습 개념)	줄 수
①	build_versions	직접	값 목록을 버전 v01, v02로, 기준선 표시. 기준선이 목록에 없으면 오류	21
②	make_result_row	빈칸 2	검색 결과 본문 목록과 결과 정보 4칸(질문, 모범 답안, 검색 결과, 답변)	19
③ 적중	find_hits	직접	단서를 글자 대조해 적중 순위와 찾은 정답 근거(한 번만 셈)	21
③ 지표	retrieval_metrics	직접	Hit(하나라도 1), Recall(찾은 근거 ÷ 전체), MRR(1 ÷ 첫 적중 순위)	17
③ nDCG	ndcg_at_k	빈칸 2	DCG와 IDCG에 순위 가중치를 더함. nDCG = DCG ÷ IDCG	11

교시 끝에 확인할 출력

- --selftest: 맞음 12/12
- 버전 v01=3, v02=5 ★, v03=10
- Q17 기준선: 3/3, nDCG 0.97

보는 포인트

- 한 번에 하나만 바꿈. 기준선도 함께 돌림
- 같은 정답 근거는 한 번만 셈
- Recall은 청크 수가 아니라 정답 근거 수

코드 4지표는 LLM 없이 글자 대조로 계산해 같은 입력이면 같은 값(교재 180쪽)

상세 보기 →

출처: hands-on/solutions/ragas/core_eval.py, README.md 6장, 교재 177, 180, 181, 188쪽

무단전재 및 배포 금지

교시 3: ⑤ 버전 비교와 ④ LLM 평가(실습 함수 4개)

비교 함수는 직접 쓰고, 원인 고르기와 ragas 지표 만들기와 채점은 빈칸을 채움

단계	함수	방식	채울 것(실습 개념)	줄 수
⑤ 비교	summarize_versions	직접	문항 점수의 평균, 기준선 대비 차이, ▲▼ 판정	31
⑤ 원인	diagnose	빈칸 3	떨어진(▼) 지표 조합으로 고칠 곳 후보(교재 187쪽 표)	23
④ 지표	build_metrics	빈칸 2	ContextPrecisionWithReference, AnswerRelevancy(llm, embeddings)	8
④ 채점	score_row	빈칸 5	지표마다 읽는 칸이 다름. await로 차례로 채점	28

교시 끝에 확인할 출력

- --selftest: 맞음 12/12
- 비교표: 기준선 행은 「-」
- Q17: 5지표 점수 5개

보는 포인트

- 지표 하나만 보면 놓침: 검색과 답변 지표를 함께 봄
- 지표마다 읽는 칸이 다름(위, 정, 출, 관, 답)
- 칸 이름이 틀리면 TypeError, 「채점 실패」

> ***LLM 점수는 흔들리므로 흔들림 폭보다 큰 차이만 개선으로 봄(교재 177쪽)***

상세 보기 →

출처: hands-on/solutions/ragas/core_eval.py, README.md 6장, 교재 177, 187, 188, 201 ~ 204쪽

무단전재 및 배포 금지

본인 코드로 바꿔 끼우기: --mine 옵션과 USE_TEACHER_CODE 목록

안 채운 함수는 강사 코드가 대신 돌므로 한 함수씩 채우며 끝까지 돌려 볼 수 있음

교체 절차

1. 명령에 --mine을 붙여 실행. my_eval.py가 없으면 템플릿을 복사해 만듦
2. my_eval.py 맨 아래 USE_TEACHER_CODE 목록에서 채울 함수 이름을 지움
3. 그 함수를 채우고(raise 줄은 지움) 확인 명령으로 실행함
4. 정상 기준(--selftest 맞음, Q17 값)을 강사 결과와 비교함
5. 막히면 이름을 목록에 다시 넣고 다음 함수로 넘어감

본인 함수의 예외는 Traceback 맨 아래 줄에 보임(score_row만 경고 한 줄)

완료 기준

- --mine --selftest가 「맞음 12/12」
- Q17 기준선: Hit 1, Recall 1.00, MRR 1.00, nDCG 0.97
- Q20 「확인 필요」 판정 맞음, Q17의 LLM 5지표 점수
- 제출: my_eval.py와 실행 화면 캡처

막혔을 때

- NotImplementedError 빈칸 N: 아직 안 채움 또는 raise 줄을 안 지움
- 429(호출 제한): 1 ~ 2분 뒤 다시, --qid와 --until로 줄임
- 강사와 LLM 점수가 다름: 정상(코드 4지표는 같아야 함)

상세 보기 →

출처: hands-on/solutions/ragas/my_eval.template.py, README.md 4장과 6장

무단전재 및 배포 금지